


Toolbox de Bioinformática

Segundo dia



Leandro de B. Gonçalves e Felipe S. Salles
Semana Temática da Biologia • IB-USP
• outubro 2026



Hoje

Agenda

01	Tópico de abertura	14:00
02	Conceitos fundamentais	14:20
03	Prática guiada no terminal	15:00
04	Exercício e discussão	16:00

Com os dados de RNA-seq podemos fazer...

Depende de: tipo de biblioteca, número de réplicas, profundidade, tamanho das leitura, ...

- Expressão diferencial
- Resposta a estímulos/coondições
- Redes de coexpressão
- Delimitação de tipos celulares
- Bioprospecção
- Chamada de SNPs
- Splicing
- Montar/anotar genomas
- Redes de regulação (miRNAs, lncRNAs, etc)
- Teste de seleção
- Evolução de níveis de expressão por famílias gênicas

Alinhamento em Bioinformática

MSA (alinhamento múltiplo) Vs. Alinhamento de leituras curtas


```
seq1      ---GTAAAA---CAA--GGGAT--ACT-GTAAAACAATTTGATGTTTT-----CAACAGCCAAGGATTGGAAAGG
seq2      ---GTAAAA---CAA-TGGGAA--ACTGGTAAAACAATTTGATGTTTTCCAAGGATT-----GAAAGG
seq3      GGAGTAAAA---CAA-TGGGAAACTGTG--AAAACAATTTGATGTTTTTAACCA--TTT-----GAAAGG
seq4      GGTGTAAAAAAACAA-TGGGAAACTGTG--AAAACAATTTGATGTTTTCAATGT-TTT-----GAAAGG
seq5      ---GTAAAAAAACAA-TGGGAAACTGTG--AAAACAATTTGATGTTTTCTTGG--ATT-----TGAAAGG
          *****      *** *****      *****      *****      *****      *****
```

- Métodos estimativos (distância)
- Métodos neurísticos (descoberta)
- Profundidade e cobertura

```
- Variante da e
ref      GTAAAACAATGGGAAACTGTAAAACAATTTGATGTTTTCAACAGCCAAGGATTGAAAGG
          ACAATG GAAACT      ACAATT GATGTT  CAACAG  AAGGAT  TGAAAG
          AATGGG AACTGT      CAATTT  TGTTTT  AACAGC  AGGATT  GAAAGG
          ATGGGA ACTGTA      AATTTG   TTTTCA  CAGCCA  GGATTT
          GGGAAA TGTAAG      TTTGAT  TTTCAA  AGCCAA  GATTTG
                   TGATGT TTCAAC  CCAAGG  TTTGAA
```

Sequenciamento Illumina®

O Illumina ainda é o padrão para RNA-seq. Plataformas como o NovaSeq X produzem bilhões de reads curtos (2×150 pb) por corrida, com baixo custo por amostra.



01

Construção de Biblioteca de cDNA

RNA convertido em cDNA, fragmentado e ligado a adaptadores

02

Sequenciamento na flowcell

Fragmentos formam clusters e são lidos base a base com fluorescência

03

Leituras forward e reverse

Cada fragmento é lido pelas duas pontas (paired-end)

04

Leituras brutas em FASTQ


Sequência e qualidade de cada base, em arquivos R1 e R2

Cobertura × profundidade

Quanto (em porcentagem %) da referência foi montada pelas *reads*.
Gera a informação primária

→ Cobertura

← Profundidade



Quantas vezes (número X) uma mesma base foi lida.

- Confiabilidade à sequência
- Chamada de variantes

Prática - Transcriptômica comparativa


Vamos avaliar a mudança do perfil de transcrição de uma célula em dois contextos diferentes.

Células CALU-3 epitélio Pulmonar


Controle X Infectada com SARS-CoV-2

A referência é o trabalho de [Blanco-Melo et al., Cell 2020](#)

Resumo- Transcriptômica comparativa



Resumo- Alinhamento: transcriptoma x genoma



01

Baixando e preparando dados

Banco de dados SRA

Sequencing Read Archive - é o maior repositório público do mundo para dados brutos de sequenciamento - **Serão nosso dados de sequenciamento**

Projeto GENCODE

Consórcio internacional para curadoria de características genéticas humanas e de camundongo - **Será nossa referência de transcriptoma humano**

Genoma de SARS-CoV2


Genoma montado ainda em 2020 - **Será nossa referência para o transcriptoma viral**

Baixar o GENCODE e o Genoma de SARS-CoV

Wget - è o programa padrão do linux para baixar arquivos usando um link



The screenshot shows the NCBI GenBank website. At the top, there is a blue header with the NIH logo and the text "National Library of Medicine National Center for Biotechnology Information". Below this, there is a search bar with the text "Nucleotide" and a dropdown menu. The main content area shows the title "Severe acute respiratory syndrome coronavirus 2 isolate Wuhan-Hu-1, complete genome" and the NCBI Reference Sequence: NC_045512.2. There are links for "FASTA" and "Graphics".



The screenshot shows the GENCODE website. At the top, there is a logo for GENCODE. Below this, there is a navigation bar with links for "Human", "Mouse", "How to access data", "FAQ", "Documentation", and "About us". The main content area shows the title "Human Release 50 (GRCh38.p14)" and a list of links: "Statistics of this release", "More information about this assembly (including patches, scaffolds and haplotypes)", and "Go to GRCh37 version of this release".

```
terminal – bash
```

```
# Genoma do SARS
```

```
$wget -O NC_045512.2.fa  
"https://eutils.ncbi.nlm.nih.gov/entrez/eutils/  
efetch.fcgi
```

```
# Referência GENCODE
```

```
$wget  
https://ftp.ebi.ac.uk/pub/databases/gencode/Gen  
code_human/latest_release/gencode.v50.transcrip  
ts.fa.gz
```

Baixar o GENCODE e o Genoma de SARS-CoV

Vamos no GitHub do nosso curso e clicar em Releases > Arquivos SRR eGENCODE



Arquivos do sequenciamento SRR

Vamos usar SRR11517744 (controle) e SRR11517748 (doença, para SARS-CoV2). Os Arquivos estarão no GitHub

Sequence Read Archive

Run Browser > SRR11517748

GSM4462352: Series7_Calu3_SARS-CoV-2_2; Homo sapiens; RNA-Seq (SRR11517748)

Metadata

Analysis

Reads

Data access

FASTA/FASTQ download

Run

Run	Spots	Bases	Size	GC Content	Data Status	Published
SRR11517748	13.6M	1.9G	827.8MB	48.5%	Public	2020-04-10

01 · Curiosidade de novo

Curiosidade: e sem um GENCODE?

(Ou seja, 99,999% das espécies)

Montamos um transcriptoma *de novo*

01

Montar transcritos

Trinity · SPAdes

02

Avaliar completude

BUSCO

03

Descobrir CDS

04

Anotar por espécie próxima



BLAST

Parálogos

Cópias parecidas se embaralham em um único transcrito e geram mais formas que existem de verdade.

Quimeras

O montador une transcritos de genes diferentes. NÃO EXISTE BIOLÓGICAMENTE

02

Controle de qualidade

FASTQ e o Phred score

Cabeçalho	@HWI-ST227:389:C4WA2ACXX:7
Sequência	GGAGGAAGGTCCTCGCTCCTCTTTCATA
Separador	+
Qualidade	FFFFHHHJJJJJJJJJJIGIG??55###

Sequência e qualidade têm o mesmo tamanho: um caractere de nota para cada base.

J

→ Q41 excelente

?

→ Q30 limiar usual

#

→ Q2 descartar

Q	erro	acurácia
Q10	1 em 10	90%
Q20	1 em 100	99%
Q30	1 em 1.000	99,9%
Q40	1 em 10.000	99,99%

$Q = -10 \cdot \log_{10}(P)$

Cada +10 divide a chance de erro por 10. A nota vira caractere ASCII somando 33 (Phred+33).

03

Criando um índice

04

Quantificando

TPM e fold change

TPM = CONTAGEM

Transcritos Por Milhão: deixa a expressão comparável entre transcritos e entre amostras.

01 Contar reads por transcrito

Reads compatíveis com mais de uma isoforma são divididas entre elas, por isso os valores saem fracionados.

02 RPK = reads ÷ tamanho efetivo (kb)


Reads Por Kilobase: transcritos longos recebem mais reads só por serem longos. O tamanho efetivo desconta o tamanho do fragmento.

03 TPM = RPK ÷ soma dos RPK × 10⁶

Corrige a profundidade: toda amostra passa a somar 1 milhão, então dá para comparar amostras.

Fold change = MUDANÇA

Quantas vezes a expressão mudou entre duas condições. Usamos em log₂.



$$\log_2 FC = \log_2 (\text{tratado} \div \text{controle})$$

Precisa vir com o p-valor ajustado.

05

Visualização dos resultados

06

Enriquecimiento funcional

Anotação funcional

01

Gene identificado

Sequência predita,
atribuída um ID

Ensembl

RefSeq

UniProt

02

Reunir evidências

Experimentos publicados

03

Curadoria pelos consórcios

ESPECIALISTAS CRIAM BANCOS DE DADOS

GO Consortium

UniProt-GOA

KEGG

FlyBase • MGI • TAIR

↓ Termos padronizados

GO • BP

Processo Biológico

ex.: apoptose, crescimento,
resposta imune

GO • MF

Função Molecular

ex.: atividade de quinase, ligação
ao DNA, Transportador de íons

GO • CC

Componente Celular

ex.: mitocôndria, REL,
Extracelular

KEGG

Via metabólica ou de sinalização

ex.: glicogenólise, Ciclo de Krebs,
Tradução de RNAs

07

Alinhamento transcriptoma x genoma

Tecnologias de sequenciamento de genomas

illumina[®]

Síntese com nucleotídeos fluorescentes em clusters na flowcell



tamanho: 2 × 150 pb

acurácia: ~99,9%

qualidade média: Q30+

PacBio ● **HiFi**

Leitura circular de uma única molécula, repetida até gerar consenso



tamanho: 15–25 kb

acurácia: ~99,9%

qualidade média: Q30+

 **OXFORD**
NANOPORE
Technologies

Corrente elétrica muda conforme o DNA atravessa um poro



tamanho: 10 k a >1 Mb

acurácia: ~99%


qualidade média: Q20+

Alinhar reads contra um genoma

Não “splice-aware”

BWA · Bowtie2


Alinhamento contínuo.



Splice-aware

STAR · HISAT2

Considera íntrons e divide a *read* entre dois éxons.



Minimap2 - Para *reads* longas - Genoma vs Genoma

08

Alinhamento apenas viral

Uma frase curta sobre o que vem a seguir

09

Análise de cobertura

Uma frase curta sobre o que vem a seguir


10

Visualização no IGV

Uma frase curta sobre o que vem a seguir

Obrigado(a)!

Dúvidas e perguntas



S E M A N A
T E M Á T I C A
D A B I O L O G I A

leandro_goncalves@usp.br



INSTITUTO DE
BIOCIÊNCIAS

