


Toolbox de Bioinformática

Segundo dia



SEMANA
TEMÁTICA
DA BIOLOGIA

Leandro de B. Gonçalves e Felipe S. Salles

Semana Temática da Biologia • IB-USP • outubro 2026



INSTITUTO de
BIOCIÊNCIAS



Hoje

Agenda

01	Pequena recapitulação	19:00
02	Introdução a conceitos fundamentais	19:20
03	Prática guiada no terminal · Transcriptômica	20:45
04	Prática guiada no terminal · Genômica	21:00

Ontem

Aula de ontem

01

Baixamos arquivo
FASTA de um DB

02

Fizemos **BLAST**


03

Alinhamos as
sequências com
MAFFT


04

Montaríamos uma
filogenia com o
IQtree

Hemoglobin A



Hemoglobin B



Alinhamento em Bioinformática

MSA (alinhamento múltiplo)

```
seq1  ---GTAAAA---CAA--GGGAT--ACT-GTAAAACAATTTGATGTTTT-----CAACAGCCAAGGATTGGAAAGG
seq2  ---GTAAAA---CAA-TGGGAA--ACTGGTAAAACAATTTGATGTTTTCCAAGGATTT-----GAAAGG
seq3  GGAGTAAAA---CAA-TGGGAAACTGTG--AAAACAATTTGATGTTTTAACCA--TTT-----GAAAGG
seq4  GGTGTAAAAAACA--TGGGAAACTGTG--AAAACAATTTGATGTTTTCAATGT-TTT-----GAAAGG
seq5  ---GTAAAAAACA--TGGGAAACTGTG--AAAACAATTTGATGTTTTCTTGG--ATT-----TGAAAGG
      *****  ***  *****  ****  *****
      *****
```

- Conjunto de sequências (genes, proteínas, CDS, etc.)
- Busca de homologia
- Métodos estimativos (distância)
- Variações são entendidas como SNPs, produtos da evolução

Alinhamento de leituras curtas

```
ref   GTAAAACAATGGGAAACTGTAAAACAATTTGATGTTTTCAACAGCCAAGGATTGAAAGG
      ACAATG GAACT      ACAATT GATGTT CAACAG AAGGAT TGAAAG
      AATGGG AACTGT      CAATTT TGTTTT AACAGC AGGATT GAAAGG
      ATGGGA ACTGTA      AATTG   TTTTCA CAGCCA GGATT
      GGGAA TGTA      TTTGAT TTTCAA AGCCAA GATTG
      TGATGT TTCAAC CCAAGG TTTGAA
```

- Milhões de reads contra uma referência ou “Scaffolding”
- Busca por “endereço”: origem, espécie, filo ...
- Métodos heurísticos (descoberta)
- Profundidade e cobertura
- Variantes são consideradas possíveis erros

Com os dados de RNA-seq podemos fazer...

Depende de: tipo de biblioteca, número de réplicas, profundidade, tamanho das leituras, ...

Expressão
diferencial

Resposta a
estímulos/co
ndições

Redes de
coexpressão

Delimitação
de tipos
celulares

Bioprospecção

Chamada de
SNPs e
variantes

Splicing


Montar
/anotar
genomas

Redes de
regulação
(miRNAs,
lncRNAs, etc.)

Evolução de
níveis de
expressão por
famílias gênicas

Sequenciamento Illumina®

O Illumina ainda é o padrão para RNA-seq. Plataformas como o NovaSeq X produzem bilhões de reads curtos (2×150 pb) por corrida, com baixo custo por amostra.



01

Construção de Biblioteca de cDNA

RNA convertido em cDNA, fragmentado e ligado a adaptadores

02

Sequenciamento na flowcell

Fragmentos formam clusters e são lidos base a base com fluorescência

03

Leituras forward e reverse

Cada fragmento é lido pelas duas pontas (paired-end)

04


Leituras brutas em FASTQ

Sequência e qualidade de cada base, em arquivos R1 e R2

Cobertura × profundidade

Quanto (em porcentagem %) da referência foi montada pelas reads.

→ **Cobertura** Gera a informação primária



Quantas vezes (número X) uma mesma base foi lida.

- Confiabilidade à sequência
- Chamada de variantes

→

Prática - Transcriptômica comparativa

Vamos avaliar a mudança do perfil de transcrição de uma célula em dois contextos diferentes.

Células CALU-3 · epitélio pulmonar

condição 1

Controle


×

condição 2


Infectada com SARS-CoV-2

A referência é o trabalho de [Blanco-Melo et al., Cell 2020](#)

Resumo - Transcriptômica comparativa



Resumo - Alinhamento: transcriptoma x genoma



Mão na massa!

01

Baixando e preparando dados

FASTQ

Banco de dados SRA

Sequencing Read Archive : é o maior repositório público do mundo para dados brutos de sequenciamento.

→ Serão nossos dados de sequenciamento

FASTA

Projeto GENCODE

Consórcio internacional para curadoria de características genéticas humanas e de camundongo.

→ Será nossa referência de transcriptoma humano

FASTA

Genoma de SARS-CoV2

Genoma montado ainda em 2020.

→ Será nossa referência para o transcriptoma viral

Baixar o GENCODE e o Genoma de SARS-CoV

wget é o programa padrão do Linux para baixar arquivos usando um link

-O

nome para o arquivo de saída

```
terminal – bash
```

```
# Genoma do SARS
```



```
$ wget -O NC_045512.2.fa  
"https://eutils.ncbi.nlm.nih.gov/entrez/eutils/efetch.fcgi"
```

```
# Referência GENCODE
```

```
$ wget  
https://ftp.ebi.ac.uk/pub/databases/gencode/Gencode_human/latest_release/gencode.v50.transcripts.fa.gz
```

De onde estamos baixando?

Lembra do NCBI e do ENA que falamos na primeira aula?



Baixar o GENCODE e o Genoma de SARS-CoV

Vamos no GitHub do nosso curso e clicar em **Releases > Arquivos SRR e GENCODE**

01 · Releases

211295 Create LinhadCodigo405cc61 · yesterday192 Commits

Curso do Departamento de Genética	Update README.md	2 weeks ago
STBio26	Update conda_downloads.md	4 days ago
Teorica	Update README.md	3 months ago
1_all_proteins.fasta.gz	Add files via upload	9 months ago
2_all_proteins.fasta.gz	Add files via upload	9 months ago
3_all_proteins.fasta.gz	Add files via upload	9 months ago
4_all_proteins.fasta.gz	Add files via upload	9 months ago
LinhadeCodigo	Create LinhadCodigo	yesterday

All classes of master degree

Activity

0 stars

0 watching

1 fork

Report repository

Releases

1 tag

Create a new release

Packages

No packages published

Publish your first package

02 · Arquivos SRR e GENCODE

Arquivos SRR e GENCODEPre-releaseCompare

LeoBroto released this 5 days agoToolbox_bioinf...2ea3de1

Arquivos usados na pratica do curso "Toolbox de Bioinformática" da Semana Temática da USP

Assets9

link → github.com/211295/Workshop/releases

Arquivos do sequenciamento SRR

Vamos usar **SRR11517744** (controle) e **SRR11517748** (doença, para SARS-CoV2). Os arquivos estarão no GitHub.

Sequence Read Archive

[Run Browser](#) > **SRR11517748**

GSM4462352: Series7_Calu3_SARS-CoV-2_2; Homo sapiens; RNA-Seq (SRR11517748)

Metadata

Analysis

Reads

Data access

FASTA/FASTQ download

Run

Run	Spots	Bases	Size	GC Content	Data Status	Published
SRR11517748	13.6M	1.9G	827.8MB	48.5%	Public	2020-04-10

Curiosidade: e sem um GENCODE?

(Ou seja, 99,999% das espécies)

Montamos um transcriptoma *de novo*

01

Montar transcritos

Trinity · SPAdes

02

Avaliar completude

BUSCO

03

Descobrir CDS

04

Anotar por espécie próxima

BLAST

Parálogos

Cópias parecidas se embaralham em um único transcrito e geram mais formas do que existem de verdade.

Quimeras

O montador une transcritos de genes diferentes. **NÃO EXISTE BIOLOGICAMENTE**

02

Controle de qualidade

FASTQ e o Phred score

Cabeçalho	@HWI-ST227:389:C4WA2ACXX:7
Sequência	GGAGGAAGGTCCTCGCTCCTCTTTCATA
Separador	+
Qualidade	FFFFHHHJJJJJJJJJJIGIG??55###

Sequência e qualidade têm o mesmo tamanho: um caractere de nota para cada base.

J

 → Q41 excelente

?

 → Q30 limiar usual

#

 → Q2 descartar

Q	erro	acurácia
Q10	1 em 10	90%
Q20	1 em 100	99%
Q30	1 em 1.000	99,9%
Q40	1 em 10.000	99,99%

$Q = -10 \cdot \log_{10}(P)$

Cada +10 divide a chance de erro por 10. A nota vira caractere ASCII somando 33 (Phred+33).

03-04


03 Criando um índice

04 Quantificando

TPM

CONTAGEM

Transcritos Por Milhão: deixa a expressão comparável entre transcritos e entre amostras.



$$\text{RPK} = \text{reads} \div \text{tamanho (kb)}$$

Transcritos maiores recebem mais reads só por serem maiores. Dividir pelo tamanho corrige isso.


$$\text{TPM} = \text{RPK} \div \text{soma dos RPK} \times 10^6$$

Normalização: total 1 milhão

Fold change

MUDANÇA

Quantas vezes a expressão mudou entre duas condições. Usamos em $\log_2$.



$$\log_2 \text{FC} = \log_2 (\text{tratado} \div \text{controle})$$


Precisa vir com o p-valor ajustado.

05-06


05 Visualização dos resultados

06 Enriquecimento funcional

Anotação funcional



↓ Termos padronizados



07

Alinhamento transcriptoma x genoma

Tecnologias de sequenciamento de genomas

illumina[®]

Síntese com nucleotídeos fluorescentes em clusters na flowcell



tamanho **2 × 150 pb** acurácia **~99,9%** qualidade média **Q30+**

PacBio **HiFi**

Leitura circular de uma única molécula, repetida até gerar consenso



tamanho **15–25 kb** acurácia **~99,9%** qualidade média **Q30+**

 **OXFORD** **NANOPORE**
Technologies

Corrente elétrica muda conforme o DNA atravessa um poro




tamanho **10 k a >1 Mb** acurácia **~99%** qualidade média **Q20+**

Alinhar reads contra um genoma

Não “splice-aware”

BWA · Bowtie2


Alinhamento contínuo.



Splice-aware

STAR · HISAT2

Considera íntrons e divide a read entre dois éxons.



Minimap2 Para reads longas · Genoma vs Genoma

08-10

- 08 **Alinhamento apenas viral**
- 09 **Análise de cobertura**
- 10 **Visualização no IGV**

Obrigado!

Dúvidas e perguntas



S E M A N A
T E M Á T I C A
D A B I O L O G I A

leandro_goncalves@usp.br



INSTITUTO DE
BIOCIÊNCIAS

